

졸업자격실험보고서

멀티 모달 데이터를 이용한 TCN  
기반 시나리오별 아파트 가격 예측  
연구

지도교수 김진석

컴퓨터공학과  
동국대학교 WISE캠퍼스

김영호

2025

졸업자격실험보고서

멀티 모달 데이터를 이용한 TCN  
기반 시나리오별 아파트 가격 예측  
연구

Multi-Modal TCN-Based Apartment Price  
Prediction under Scenario Analysis

김영호

지도교수 김진석

본 보고서를 졸업자격 실험보고서로 제출함.  
2025년 11월 21일

김영호의 졸업자격 실험보고 통과를 인준함.  
2025년 11월 21일

주 심 도재수 (인)

부 심 김진석 (인)

동국대학교 컴퓨터공학과

# 목 차

1. 서론 .....	1
1.1 연구배경 및 목적 .....	1
1.2 연구범위 .....	1
2. 이론적 배경 .....	3
2.1 관련 개념 .....	3
2.2 선행 연구 .....	6
3. 시스템 설계 .....	8
3.1 요구사항 .....	8
3.2 아키텍처 설계 .....	10
4. 프로그램 구현 .....	12
4.1 시스템 환경 .....	12
4.2 시스템 구성 .....	12
4.3 시스템 구현 .....	13
5. 실험 .....	18
5.1 위성 이미지 효과성 검증 .....	18
5.2 경제지표 데이터 영향 분석 .....	18
5.3 최종 모델 성능 비교 .....	18
5.4 시나리오 설계 .....	19
5.5 시나리오 예측 .....	19
5.6 예측 결과 .....	20
6. 결론 .....	21
참고문헌 .....	22
부록 .....	24

## 그림 목 차

[그림 2-1] 스킵 연결 구조 .....	4
[그림 2-2] LSTM의 구조 .....	5
[그림 2-3] TCN의 구조 .....	11
[그림 3-1] 유스케이스 다이어그램 .....	9
[그림 3-2] 시스템 아키텍처 .....	11
[그림 3-3] 클래스 다이어그램 .....	11
[그림 3-4] 순차 다이어그램 .....	12
[그림 4-1] 시스템 구성 .....	13
[그림 4-2] 타겟 변수를 제외한 수치형 변수 분포 .....	14
[그림 4-3] 증강된 위성 이미지 예시 .....	15
[그림 4-4] 면적당 단가(만원)의 이상치 .....	15
[그림 5-1] 최종 예측 결과 .....	21

## 표 목 차

[표 3-1] 요구사항 명세서 .....	8
[표 3-2] 유스케이스 명세서 .....	10
[표 4-1] 시스템 환경 표 .....	12
[표 4-2] 데이터 구성 .....	13
[표 4-3] 정규화 기법 비교 표 .....	16
[표 4-4] 스케일링 기법 비교 표 .....	17
[표 5-1] 비정형 데이터 활용 효과 결과 .....	18
[표 5-2] 최종 모델 성능 비교 .....	18
[표 5-3] 시나리오별 월별 변화율 .....	19

# 1. 서론

## 1.1 연구배경 및 목적

대한민국의 가계 자산 구조는 부동산에 크게 편중되어 있다. 통계청 가계금융복지조사(2024년)[1]에 따르면, 가구 자산의 75.2%가 실물자산이며 이 중 대부분은 부동산이다[2]. 이는 주요 선진국 대비 약 2~3배 높은 수준으로[3], 부동산 가격 변동이 가계 경제에 미치는 영향이 크다는 것을 의미한다. 이처럼 부동산이 국민 자산에서 차지하는 높은 비중은, 정확한 가격 예측 모델 개발이 중요한 사회적, 경제적 과제를 보여준다.

이러한 중요성에 따라 예측 정확도를 높이기 위한 다양한 시도들이 이루어져 왔다. 특히 위성 이미지를 활용한 가격 예측은 전 세계적으로 활발히 연구되는 분야이다. LA의 부동산 시세를 예측하기 위해 위성지도를 사용하였고, 성능이 향상되는 결과를 보여주었다[4]. 나아가 최근에는 위성 이미지뿐만 아니라 주택 특성, 지리 정보, 텍스트 등 여러 종류의 데이터를 통합하는 멀티모달(multi-modal) 접근법이 주목받고 있다. 선행 연구들은 실내외 이미지, 위성 이미지 등 다양한 시각 정보를 결합하여 단일 데이터 기반 모델보다 우수한 예측 성능을 달성할 수 있음을 보여주었다[5],[6].

그러나 선행 연구들은 다음과 같은 한계점을 보였다. 첫째, 단일 시점의 데이터만 사용하여 예측하였다[4],[7]. 이는 시계열 예측보다는 단순한 회귀적 설명에 가깝다는 한계가 있다. 이러한 단순 회귀적 설명은 시장 참여자들의 자산 증식에 도움을 주지 못한다는 단점을 가진다. 둘째, 시계열 예측을 수행한 일부 연구들 또한 미래에 대한 단일한 결과만을 제시하는 결정론적 예측(deterministic forecasting)[8]에 머무르는 경향을 보였다. 이러한 접근법은 금리 변동이나 정책 변화와 같은 미래의 불확실성을 반영하지 못하므로, 시장 참여자들에게 실질적인 의사결정 정보를 제공하는 데 한계가 있다.

따라서 본 연구는 선행 연구들을 확장하여, 아파트 단지 정보와 위성 이미지 데이터에 주요 거시 경제지표를 결합하여 시계열 데이터셋을 구축하고, 대표적인 시계열 모델을 학습시켜 가장 성능이 좋은 모델을 선택한다. 나아가 미래 경제 상황을 가정한 시나리오 분석을 적용하여, 낙관적·중립적·보수적 관점의 미래 가격 변동 범위를 예측하는 것을 최종 목적으로 한다. 이를 통해 데이터 기반의 종합적인 부동산 예측 모델을 제시하고자 한다.

## 1.2 연구범위

본 연구의 구체적인 연구 범위는 다음과 같이 정했다.

첫째, 시간적 범위는 2018년 7월부터 2025년 7월까지로 설정하였다. 이 기간은 본 연구에서 활용하는 아파트 매매 기록, 거시 경제지표, 위성 이미지 등 모든 데이터를 일관성 있게 수집할 수 있는 최대의 기간이다.

둘째, 공간적 범위는 서울특별시 강남구로 한정하였다. 강남구는 서울 전체 아파트 시가 총액의 약 43%가 집중된 핵심 지역으로, 부동산 시장의 동향을 대표적으로 파악할 수 있다[9]. 또한, 관련 선행 연구가 강남구를 대상으로 수행된 바 있어, 본 연구에서도 강남구를 연구 대상으로 선정하는 것이 타당하다고 판단하였다[10].

넷째, 데이터는 아파트 거래 기록과 거시 경제지표로 구성된 정형 데이터 및 위성 이미지로 구성된 비정형 데이터를 통합하여 활용한다.

마지막으로 예측 모델은 전통적인 시계열 분석 모델인 GRU, LSTM과 CNN 모델인 TCN을 적용해 성능을 비교하고 분석하며, 가장 성능이 좋은 모델을 최종적으로 선택한 다음 시나리오 분석을 통해 향후 12개월 간의 미래 가격 변동 범위를 낙관적, 중립적, 보수적 관점에서 제시하는 것으로 한다.

## 2. 이론적 배경

### 2.1 관련 개념

#### 2.1.1 시나리오 분석

미래를 예측하는 접근법은 크게 단 하나의 결과만을 제시하는 결정론적 예측(deterministic forecasting)과 발생할 여러 결과의 가능성을 확률로 분석하는 확률론적 예측(probabilistic forecasting)으로 나뉜다. 시나리오 분석은 이 중 후자의 개념에 속하면서도, 불확실한 요인의 가능한 미래 값들을 구체적이고 명확한 시나리오로 생성하는 전략적 예측 방법론이다.

이 방법은 생성되는 시나리오의 수를 조절하여 계산 비용을 관리할 수 있고, 각 시나리오에 발생 가능성을 나타내는 확률을 부여할 수 있다는 장점이 있다. 무엇보다 의사결정자에게 연속적이고 명확한 미래 상황을 제공함으로써, 의사결정에 영향을 미치는 주요 불확실성을 강조하고 더욱 유연한 전략 수립을 가능하게 한다[12].

본 연구에서는 이러한 시나리오 분석의 장점을 활용하여 미래 부동산 시장의 불확실성에 대응하고자 하였다. 아파트 가격에 영향을 미치는 주요 거시 경제지표(소비심리지수, 경기종합지수 등)를 핵심 동인(key drivers)으로 설정하였다. 핵심 동인이란 어떤 결과나 미래 상황을 이끌어가는 가장 핵심적인 원인이나 변수를 의미한다[12]. 이 지표들이 미래에 긍정적으로 변화하는 상황(낙관적), 현재 추세를 유지하는 상황(중립적), 그리고 부정적으로 변화하는 상황(보수적)을 각각의 시나리오로 가정하였다. 시나리오별로 미래 가격 변동 범위를 예측함으로써, 시장 참여자들은 잠재적인 기회와 리스크를 종합적으로 평가하고 데이터에 기반한 합리적인 의사결정을 내릴 수 있다.

#### 2.1.2 멀티모달 학습

부동산 가격은 다양한 요인의 복합적인 상호작용에 의해 결정되므로 예측이 매우 어려운 과제로 알려져 있다. 이러한 복잡성에 대응하기 위해, 여러 형태(modality)의 데이터 소스를 통합하는 멀티모달 학습이 주목받고 있다.

멀티모달 학습은 텍스트, 이미지, 수치 데이터 등 서로 다른 유형의 데이터를 적절히 융합하여 단일 모델로 학습시키는 방법론이다. 각 데이터 형태는 대상에 대한 고유한 정보를 담고 있으므로, 이를 융합하면 단일 데이터 소스만 사용했을 때보다 더 풍부하고 뚜렷한 특징을 학습하여 모델의 전반적인 성능을 향상할 수 있다.

예를 들어, 아파트 가격 예측 문제에서 정형 데이터(건축 연도, 면적 등)는 객관적인 물리적 특성을 제공하지만, 아파트가 위치한 지역의 실제 모습이나 주변 환경의 질적 가치를 담아내기에는 한계가 있다. 반면, 위성 이미지 데이터는 녹지 비율, 건물 밀도, 도로 접근성 등 정형 데이터로 표현하기 어려운 공간적, 환경적 맥락을 시각적으로 제공한다.

이에 본 연구에서는 이러한 데이터의 상호 보완성에 주목하여, 각 데이터 형태에 최적화된 모델로 특징을 추출한 뒤 이를 융합하는 멀티모달 접근법을 채택하였다. 이를 통해 아파트의 개별적 특성과 거시적 환경 요인을 동시에 고려하는 종합적인 예측 모델을 구축하고자 하였다.

#### 2.1.3 MLP

다층 퍼셉트론(multi-layer perceptron, MLP)은 인공 신경망(artificial neural network)




의 가장 기본적인 형태로, 입력층(input layer), 하나 이상의 은닉층(hidden layer), 그리고 출력층(output layer)으로 구성된 순방향 네트워크이다. 단층 퍼셉트론이 해결할 수 없었던 비선형적 문제를 해결할 수 있게 하여 딥러닝의 가장 기본적인 모델이다.

MLP의 각 노드(뉴런)는 이전 층의 모든 노드와 가중치(weight)를 통해 연결되어 있으며, 입력값에 가중치를 곱한 값들의 합을 계산한다. 이 값은 비선형성을 도입하기 위한 활성화 함수(activation function)를 거쳐 다음 층으로 전달된다. 이 과정이 입력층에서 출력층까지 순차적으로 진행되는 것을 순전파(forward propagation)라 한다. 모델의 학습은 출력층에서 계산된 예측값과 실제 정답 간의 오차(loss)를 계산하고, 이 오차를 기반으로 각각의 가중치를 미세 조정하는 역전파(backpropagation) 알고리즘을 통해 이루어진다.

본 연구에서 MLP는 최종 시계열 예측을 위한 주 모델이 아닌, 다양한 정형 데이터를 압축적인 특징 벡터로 변환하는 역할로 활용되었다. 아파트의 개별 특성(전용면적, 층, 건축 연도 등)과 거시 경제지표로 구성된 정형 데이터는 그 자체로 복잡한 비선형 관계를 내포하고 있다. MLP는 이러한 데이터들을 입력으로 받아 여러 은닉층을 통과시키면서 데이터 내에 고차원 패턴을 학습한다. 최종적으로 출력층 직전의 은닉층에서 나온 벡터를 해당 정형 데이터의 핵심 특징이 압축된 표현으로 사용하였다. 이렇게 생성된 특징 벡터는 위성 이미지로부터 추출된 시각적 특징 벡터와 결합해, 멀티모달 시계열 예측 모델의 최종 입력 데이터로 사용된다.

#### 2.1.4 Resnet

ResNet(residual network)은 마이크로소프트가 2015년 ILSVRC 대회에서 제안한 CNN 구조로, 네트워크가 깊어질수록 발생하는 성능 저하와 기울기 소실(vanishing gradient) 문제를 근본적으로 해결하기 위해 고안되었다. 일반적인 심층 네트워크는 층이 깊어질수록 역전파 과정에서 기울기가 점점 작아져 학습이 불안정해지고, 오히려 얇은 네트워크보다 정확도가 떨어지는 현상이 나타난다. 이러한 현상을 해결하기 위한 ResNet의 핵심 아이디어는 잔차 학습(residual learning)이다. 잔차 학습이란 기존 네트워크는 입력( $x$ )을 학습을 통해 최종 출력( $H(x)$ )을 직접 맞추도록 진행되는 것과 달리, ResNet은 출력( $H(x)$ )과 입력( $x$ )의 차이인 잔차( $F(x) = H(x) - x$ )를 학습한다. 즉, 블록의 출력은 다음과 같이 표현된다. 여기서  $F(x)$ 는 학습해야 할 잔차 함수이며,  $x$ 는 입력이다. 입력  $x$ 는 네트워크 내부를 우회하여 출력과 직접 더해지는데, 이러한 구조를 스킵 연결(skip connection)이라 한다. 스킵 연결의 개념적 구조는 [그림 2-1]과 같다. 이 방식은 정보 손실을 최소화하고, 깊은 층에서도 기울기의 흐름을 원활하게 유지해 학습을 안정화한다.




[그림 2-1] 스킵 연결 구조

이후 ResNet 구조는 DenseNet, ResNeXt, EfficientNet 등 다양한 모델의 기반으로 확장되었으며, 오늘날 심층 신경망 설계의 표준적 프레임워크로 자리 잡았다.

### 2.1.5 LSTM

LSTM(long-short-term memory, LSTM)은 전통적인 RNN의 장기 의존성 문제를 해결하기 위해 설계된 순환 신경망의 한 종류이다. LSTM의 핵심은 셀 상태(cell state)라는 별도의 정보 흐름 경로를 두어, 정보가 여러 타임 스텝을 거치더라도 손실 없이 전달될 수 있도록 하는 것이다. 기본적인 LSTM의 구조는 [그림 2-2]와 같다.



[그림 2-2] LSTM의 구조

이 셀 상태는 망각 게이트(forget gate), 입력 게이트(input gate), 출력 게이트(output gate)라는 세 가지 게이트에 의해 정교하게 제어된다. 망각 게이트는 과거 정보 중 어떤 것을 버릴지 결정하고, 입력 게이트는 현재 입력으로부터 어떤 새로운 정보를 셀 상태에 저장할지 결정한다. 마지막으로 출력 게이트는 업데이트된 셀 상태를 기반으로 어떤 값을 출력으로 내보낼지 결정한다. 이러한 구조 덕분에 LSTM은 시계열 데이터 내에서 단기적인 패턴뿐만 아니라 매우 긴 시간 간격을 가진 패턴까지 효과적으로 학습할 수 있다.

### 2.1.6 GRU

GRU(gated recurrent unit, GRU)는 LSTM과 마찬가지로 장기 의존성 문제를 완화하기 위해 제안된 구조지만, LSTM을 간소화한 형태이다.

GRU는 LSTM과 달리 리셋 게이트(reset gate)와 업데이트 게이트(update gate) 두 개의 게이트만 사용한다. 리셋 게이트는 과거 은닉 상태 중 현재 입력과 관련이 적은 정보를 얼마나 제거할지를 결정하여 불필요한 기억을 초기화한다. 반면 업데이트 게이트는 이전 은닉 상태를 얼마나 유지하고 새로운 입력 정보를 얼마나 반영할지를 제어한다.

이 두 게이트의 상호작용을 통해 GRU는 입력 시점마다 과거 정보의 중요도를 동적으로 평가한다. 즉, 관련성이 낮은 과거 정보는 리셋 게이트를 통해 효과적으로 제거하고, 중요한 정보는 업데이트 게이트를 통해 장기간 유지함으로써 정보 흐름의 효율성을 극대화한다. 이러한

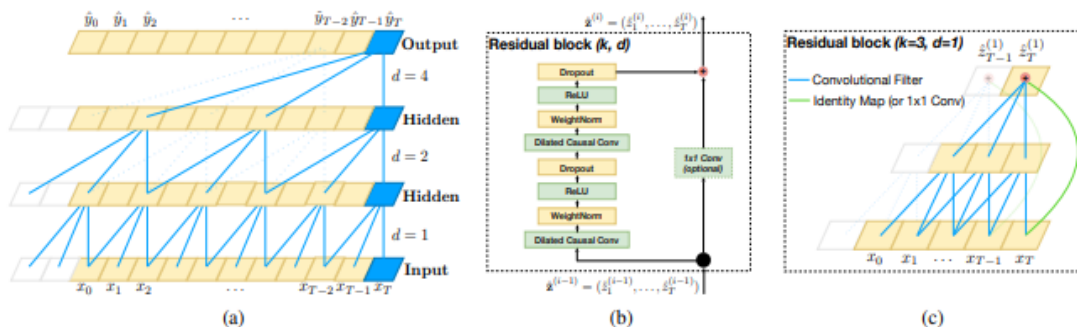
설계 덕분에 GRU는 LSTM보다 구조가 단순하고 계산 효율성이 높으며, 다양한 시계열 문제에서 사용된다.

### 2.1.7 TCN

TCN은 시계열 데이터 분석을 위해 제안된 모델로, RNN 계열이 가지는 장기 의존성 문제와 기울기 소실 문제를 해결하기 위한 대안으로 주목받고 있다. 순환 구조를 기반으로 하는 RNN은 시간 순서에 따라 연산이 직렬적으로 진행되므로 시간이 오래 걸린다는 단점이 있고, 긴 시퀀스에서 과거 정보가 희석되는 장기 의존성 문제가 있다. 이에 반해 TCN은 CNN 구조를 시계열 분석에 적용함으로써, 병렬 연산이 가능하고 기울기 흐름이 안정적인 구조를 제공한다.

첫째, TCN은 [그림 2-3]과 같이 두 가지 합성곱 방식을 결합하여 시계열 데이터의 특성을 반영한다. 우선 인과적 합성곱(causal convolution)을 사용하여 시간적 인과성을 보장한다. 이는 시점  $t$ 의 출력을 계산할 때 미래 시점의 정보를 참고하지 않고, 오직 과거 시점의 입력만 활용하도록 설계된 방식이다. 또한, 팽창 계수(dilation factor)  $d$ 는 필터가 입력 데이터를 건너뛰며 참조하는 간격을 의미한다. [그림 2-3(a)]에서 볼 수 있듯이  $d=1$ 일 때는 인접 데이터를,  $d=4$ 일 때는 4칸 건너의 데이터를 참조한다. 이처럼 계수  $d$ 를 층마다 지수적으로 증가 시킴으로써, 적은 수의 레이어로도 매우 넓은 수용 영역(receptive field)을 확보할 수 있다.

둘째, [그림 2-3(b)]에서 나타난 바와 같이 잔차 블록을 기본 구조로 채택하여 학습의 안정성을 높였다. 이는 ResNet의 잔차 학습 구조를 도입한 것으로, 깊은 네트워크에서도 정보 손실이나 기울기 소실없이 안정적인 학습을 지원한다. [그림 2-3(c)]는 이러한 잔차 연결의 예시를 보여주는데, 초록색 선으로 표시된 항등 매핑(identity mapping)을 통해 입력 정보가 후속 층으로 직접 전달됨을 확인할 수 있다. 이러한 구조적 특성 덕분에 TCN은 RNN과 달리 연산을 완전히 병렬화할 수 있으며, 긴 시퀀스에서도 장기 의존성을 안정적으로 학습할 수 있다.



[그림 2-3] TCN의 구조

## 2.2 선행 연구

부동산 가격 예측의 정확도를 향상하기 위한 선행 연구들은 크게 사용되는 데이터의 확장 모델링 기법의 고도화라는 두 가지 방향으로 발전해 왔다. 본 절에서 검토한 선행 연구들은 기존 정형 데이터 중심의 분석이 가진 한계를 극복하기 위해 다양한 접근 방식을 시도하였으며, 다음과 같이 정리할 수 있다.

첫째, 공간 정보의 정량화에 대한 시도이다. 기존의 분석은 상권이나 편의시설의 단순한 갯수나 거리는 반영할 수 있었으나, 시설의 밀집도나 실제 주거 환경이 주는 시각적 정보는 포

작하지 못했다. 이에 대해서 정현조 외(2023)는 커널 밀도 추정을 통해 시설의 공간 분포를 정량화하여 MLP 모델에 학습시켰고, Bency 외(2017), Hasan 외(2024)는 위성 이미지를 직접 활용하여 모델이 입지와 주변 환경의 가치를 스스로 학습하도록 유도했다. 이들의 연구들은 공통으로 비정형 데이터가 정형 데이터와 결합하여 기존 모델의 성능을 향상할 수 있음을 입증하였다.

둘째, 멀티 모달 데이터 융합의 확장이다. Hasan 외(2024), Ali Nouriano(2022)는 위성 이미지뿐만 아니라 텍스트 설명, 내부와 외부의 사진 등 주택과 관련된 모든 형태의 데이터를 결합하는 멀티 모달 딥러닝 접근법을 제안했다. 이는 단일 데이터 소스만으로는 포착하기 어려운 가격 결정 요인들을 상호 보완적으로 학습할 수 있음을 보여주었으며, 본 연구가 지향하는 정형 데이터와 비정형 데이터 융합의 이론적 토대가 되었다.

셋째, 시계열 모델링선택 폭의 확장이다. 데이터의 형태뿐만 아니라, 시계열 데이터를 다루는 모델 자체에 관한 연구도 이어졌다. Bai 외(2018) 연구는 시계열 예측의 표준으로 여겨지던 RNN(LSTM/GRU)이 가진 장기 의존성 문제와 연산 비효율성을 지적하며, TCN을 대안으로 제시했다. 이는 긴 시퀀스의 부동산 데이터를 다뤄야 하는 본 연구에 있어, 기존 LSTM 모델을 넘어서 새로운 모델의 적용 가능성을 시사한다.

종합하면, 선행 연구들은 위성 이미지와 같은 비정형 데이터의 활용이 예측 성능을 높이는 핵심 열쇠임을 공통으로 지적하고 있으며, 시계열 분석에 있어 TCN과 같은 모델의 도입 필요성을 제기하고 있다. 그러나 이러한 성과에도 불구하고, 본 연구가 해결하고자 하는 두 가지 한계점이 존재한다.

첫째, 정적인 횡단면 분석의 한계이다. 정현조 외(2023), Hasan 외(2024)등의 연구는 멀티 모달 데이터를 RNN이 아닌 MLP 모델에 입력하여 특정 시점의 가격을 예측하는 횡단면 예측을 수행하였다. 이러한 접근은 부동산 시장의 동적인 흐름을 반영하지 못하며, 시장 참여자들의 자산 증식에 실질적인 도움을 주지 못하는 단점이 있다.

둘째, 결정론적 예측의 한계이다. 대부분의 기존 연구는 미래에 대한 단일한 예측값만을 제시한다. 이러한 방법론은 금리 변동이나 정책 변화와 같은 미래 부동산 시장의 불확실성을 반영하지 못한다는 단점이 있다.

따라서 본 연구는 이러한 선행 연구의 성과를 통합하여, 위성 이미지 기반의 멀티 모달 학습을 통해 공간 정보를 반영하고, TCN 모델을 통해 시계열 예측 성능을 극대화하며, 나아가 시나리오 분석을 접목하여 미래 시장의 변동성까지 포괄하는 통합적인 예측 프레임워크를 제안하고자 한다.

### 3. 시스템 설계

#### 3.1 요구사항

본 연구는 데이터 수집에서부터 전처리, 멀티모달 특징 벡터 변환, 시계열 모델 학습 및 평가, 그리고 시나리오 기반 예측에 이르는 파이프라인을 수행하도록 구성되었다.

이를 위해 본 연구는 다른 형태의 데이터를 효과적으로 처리하기 위해 다음과 같은 방법을 채택하였다. 첫째, 실거래가와 거시 경제지표 등 정형 데이터는 MLP 모델을 통과시켜 정형 벡터로 변환한다. 둘째, 아파트의 공간적 특성을 담은 위성 이미지는 ResNet-50과 MLP를 결합한 모델을 통해 비정형 벡터로 변환한다.

이렇게 추출된 두 종류의 벡터는 융합 및 축소 과정을 거쳐 하나의 멀티 모달 데이터셋을 구축하며, 이는 시계열 예측에 특화된 세 가지 딥러닝 모델(GRU, LSTM, TCN)의 입력으로 사용된다.

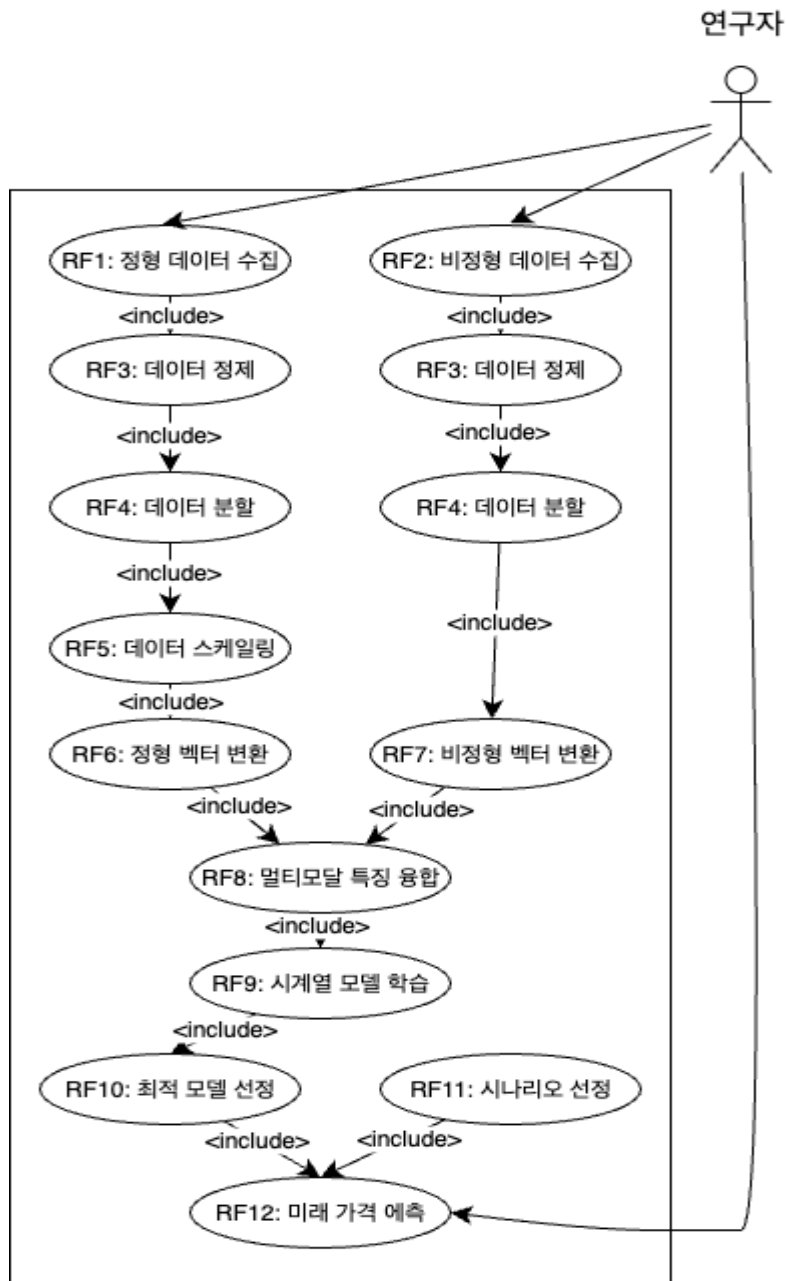
이 세 모델 중 MAE 평가지표를 기준으로 가장 성능이 좋은 모델을 선정한다. 최종적으로는 선정된 최적 모델을 활용하여 거시 경제 지표에 따른 시나리오별 미래 가격을 예측한다. [표 3-1]은 이러한 연구과정을 구체화한 기능적 요구사항을 요약한 것이다.

[표 3-1] 요구사항 명세서

구분	ID	요구사항	상세 내용
데이터 수집 및 전처리	RF-01	정형 데이터 수집	아파트 실거래가, 거시 경제지표 데이터를 수집
	RF-02	비정형 데이터 수집	아파트 좌표를 기준으로 위성 이미지 수집
	RF-03	데이터 정제	결측치를 포함한 행을 제거, 데이터를 시간순으로 정렬
	RF-04	데이터 분할	전체 데이터를 7:2:1 비율로 훈련, 검증, 테스트셋으로 분할
	RF-05	데이터 스케일링	수집된 데이터를 스케일링을 적용
	RF-06	정형 특징 벡터 변환	전처리된 정형 데이터를 MLP 모델에 통과시켜 특징 벡터로 변환
	RF-07	비정형 특징 벡터 변환	위성 이미지를 ResNet-50과 MLP를 통해 특징 벡터로 변환
모델 학습 및 평가	RF-08	멀티모달 특징 융합	정형 벡터, 비정형 벡터를 결합, 축소하고 최종 데이터셋을 구축
	RF-09	시계열 모델 학습	GRU, LSTM, TCN 모델을 학습
	RF-10	최적 모델 선정	MAE 평가지표를 기준으로 3개의 모델의 성능을 비교후, 가장 좋은 모델 선정
모델 예측	RF-11	시나리오 설정	거시 경제지표를 기준으로 낙관적, 중립적, 보수적 3가지 시나리오를 설정
	RF-12	미래 가격 예측	선정된 TCN 모델과 시나리오를 바탕으로 예측

##### 3.1.1 유스케이스 다이어그램

[그림 3-1]은 본 연구에서 구현한 파이프라인의 유스케이스 다이어그램을 나타낸 것이다. 본 시스템의 주요 요구사항은 데이터 수집, 데이터 전처리, 모델 훈련, 평가 및 선정, 시나리오 설정, 미래 가격 예측으로 이루어져 있다.



[그림 3-1] 유스케이스 다이어그램

### 3.1.2 유스케이스 명세서

본 절에서는 시스템의 핵심 기능 요구사항을 5단계(데이터 수집, 데이터 전처리, 특징 벡터 변환, 모델 학습 및 평가, 모델 예측)로 분류하여 [표 3-2]에 요약하였다. 본 시스템의 유일한 액터는 '연구자'이며, 모든 프로세스는 선행 조건에 따라 순차적으로 진행됨을 전제로 한다. 요구사항(RF)별 상세 내용과 예외 흐름은 다음과 같다.

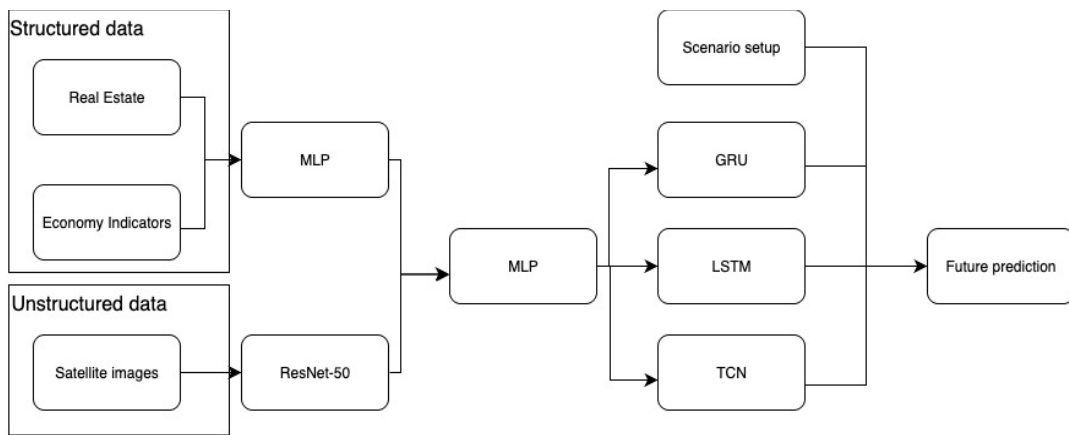
[표 3-2] 유스케이스 명세서

구분	ID	요구사항 명	상세 내용	선행 조건
1. 데이터 수집	RF-01	정형 데이터 수집	아파트 실거래가, 거시 경제지표 데이터를 수집한다.	없음
	RF-02	비정형 데이터 수집	정형 데이터의 도로명 주소를 좌표로 변환 후, GEE에서 위성 이미지를 수집한다.	RF-01
2. 데이터 전처리	RF-03	데이터 정제	수집된 데이터의 결측치를 제거하고 시간 순서대로 정렬한다.	RF-01, RF-02
	RF-04	데이터 분할	데이터 누수 예방을 위해, 정제된 데이터를 7:2:1 비율로 분할한다.	RF-03
	RF-05	데이터 스케일링	분할된 정형 데이터를 최적의 조합으로 스케일링한다.	RF-04
3. 특징 벡터 변환	RF-06	정형 벡터 변환	스케일링된 정형 데이터를 MLP 모델에 통과시켜 64차원의 특징 벡터로 변환한다.	RF-05
	RF-07	비정형 벡터 변환	수집된 위성 이미지를 ResNet-50과 MLP에 통과시켜 32차원의 특징 벡터로 압축/변환한다.	RF-04
4. 모델 학습 및 평가	RF-08	멀티모달 특징 융합	64차원의 정형 벡터와 32차원의 비정형 벡터를 MLP에 투입, 256차원의 멀티모달 데이터셋을 구축한다.	RF-06, RF-07
	RF-09	시계열 모델 학습	멀티모달 데이터셋을 GRU, LSTM, TCN 모델에 각각 학습시킨다.	RF-08
	RF-10	최적 모델 선정	MAE 평가지표를 기준으로 3개 모델의 성능을 비교 분석하여 최적의 모델을 선정한다.	RF-09
5. 모델 예측	RF-11	시나리오 설정	거시 경제지표 변화율을 기준으로 낙관적, 중립적, 보수적 3가지 시나리오를 설정한다.	RF-01
	RF-12	미래 가격 예측	선정된 모델과 3가지 시나리오를 바탕으로 미래 아파트 가격을 예측한다.	RF-10, RF-11

### 3.2 아키텍처 설계

#### 3.2.1 시스템 구성

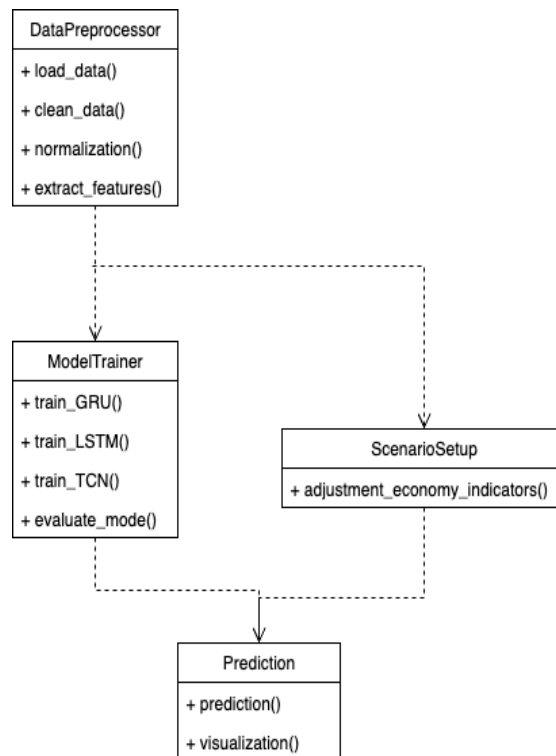
[그림 3-2]는 본 연구에서 제안하는 멀티모달 시계열 예측 시스템의 전체 아키텍처를 도식화한 것이다. 시스템의 입력 데이터는 크게 두 가지 유형으로 구분된다. 첫째는 아파트의 실거래가와 거시 경제 지표로 구성된 정형 데이터이며, 둘째는 위성 이미지인 비정형 데이터이다. 본 아키텍처는 이 두 형태의 데이터를 효과적으로 처리하기 위해 다음과 같은 구조를 채택하였다. 정형데이터는 MLP 모델에 투입된다. 이는 수치적 특성들을 압축하고, 변수 간의 비선형 관계를 학습하여 고차원의 정형 특징 벡터로 변환하기 위함이다. 그다음, 비정형 데이터는 사전 학습된 ResNet-50 모델을 통과한다. 그 결과 고차원의 비정형 특징 벡터로 변환된다. 다음으로 특징 융합 단계로 이어진다. 두 모델로부터 추출된 개별 특징 벡터들은 다시 한번 중앙의 MLP 모델을 통해 결합한다. 이 방법을 통해 서로 다른 두 데이터 간의 복잡한 상호작용을 학습하여, 최종적으로 멀티모달 데이터셋을 구축한다. 이렇게 생성된 데이터셋으로 시계열 예측에 특화된 세 가지 주요 딥러닝 모델에 학습시킨다. MAE를 기준으로 성능평가를 하여 최종적으로 시나리오 예측에 사용될 모델을 선정한다. 이후 시나리오 설정(scenario setup) 단계에서 정의된 미래 거시 경제지표의 변화율을 토대로, 선정된 최적의 모델이 미래의 아파트 가격을 예측하게 된다.



[그림 3-2 ] 시스템 아키텍처

### 3.2.2 클래스 다이어그램

[그림 3-3]은 앞서 정의한 아키텍처를 클래스로 모델링 한것이다. DataPreprocessor는 데이터 전처리, ModelTrainer는 모델의 학습 및 평가, ScenarioSetup은 시나리오의 설정, Prediction은 미래 예측 계층이다. 각 클래스는 독립적으로 실행되어 전체적인 파이프라인을 구성한다.



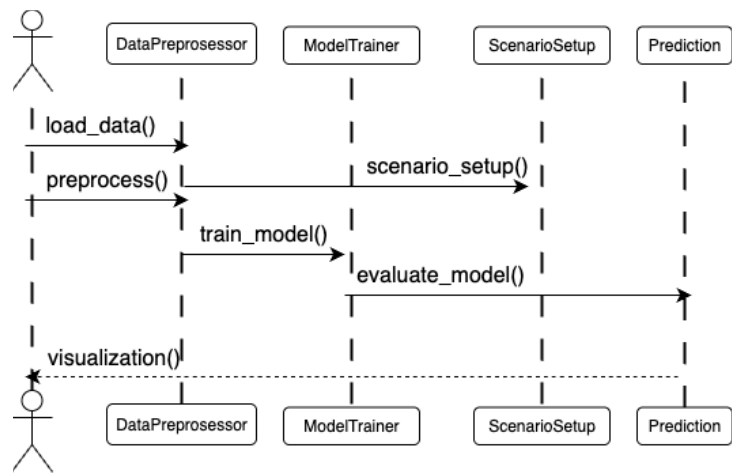
[그림 3-3] 클래스 다이어그램

### 3.2.3 순차 다이어그램

[그림 3-4]는 전체 동작 절차를 시간의 흐름에 따라 표현한 순차 다이어그램이다. 사용자가 시스템을 작동하면 데이터가 로드되고, 전처리 과정을 거쳐 모델의 학습 단계와 시나리오 설



정 단계로 전달된다. 이후 선정된 모델과 준비된 시나리오를 토대로 미래를 예측하고 예측된 가격을 시각화하여 사용자에게 보여준다.



[그림 3-4] 순차 다이어그램

## 4. 프로그램 구현

### 4.1 시스템 환경


본 시스템의 개발 및 실험은 아래 [표 4-1]과 같은 하드웨어 및 소프트웨어 환경에서 진행되었다. 모든 구현은 Python 기반으로 하며, 데이터 처리 및 딥러닝 모델링을 위해 관련 오픈소스 라이브러리를 활용 하였다.

[표 4-1] 시스템 환경 표

구분	내용	비고
하드웨어	CPU	Apple M4
	RAM	16GB
소프트웨어	macOS Sonoma	개발 운영 체제
	Python 3.11	주 개발 언어

### 4.2 시스템 구성

구현된 시스템은 데이터의 흐름에 따라 데이터 준비 모듈, 특징 추출 모듈, 모델 학습 모듈, 시나리오 예측 모듈로 네 가지 핵심 모듈로 구성된다. 각 모듈은 독립적인 Python 스크립트로 구현되었으며 이전 모듈의 출력파일(.npy, .pkl등)을 다음 모듈의 입력으로 사용하여 서로 연결된다. 전체적인 시스템 구성은 [그림 4-1]과 같다. 먼저 데이터 준비 모듈은 원본 CSV 파일을 로딩하고 전처리와 시간순으로 정렬한 뒤, 7:2:1 비율로 훈련, 검증, 테스트 데이터 셋으로 분할하는 역할을 한다. 특징 추출 모듈은 분할된 각 데이터셋을 입력받아 MLP와 ResNet-50을 통해 특징 벡터를 생성하고 파일로 저장한다. 모델 학습 모듈은 저장된 특징 벡터 파일들을 불러와 융합하고 GRU, LSTM, TCN 모델을 학습시킨 후 테스트셋으로 성능을 평가한다. 마지막 시나리오 예측 모듈에서는 가장 성능이 좋은 모델을 선정하여 시나리오에 따른 미래 가격을 예측하고 결과를 출력한다.



[그림 4-1] 시스템 구성

### 4.3 시스템 구현

#### 4.3.1 데이터셋 구성

본 연구는 아파트 매매가격에 영향을 미치는 다양한 요인을 반영하기 위해 [표 4-1]과같이 정형 및 비정형 데이터를 통합하여 사용하였다. 데이터 수집 기간은 2018년 7월부터 2025년 7월까지 설정하였다. 데이터셋 구축은 아파트 매매 자료수집부터 시작하였다. 총 7년 치 (2018.07~2025.07)의 서울특별시 강남구 아파트 매매 데이터는 국토교통부에서 제공하는 실거래가 공개 시스템을 통해 수집하였다. 다음으로 비정형 데이터인 위성 이미지를 수집하기 위해 GEE(google earth engine, GEE) 서비스를 활용하였다. GEE는 과거 시점의 위성 사진을 접근할 수 있는 플랫폼으로 본 연구에 채택되었다. 거래된 아파트의 정확한 위치 좌표가 GEE 사용에 필수이므로, 카카오맵(Kakao MAP) Open API를 이용하여 수집된 아파트의 도로

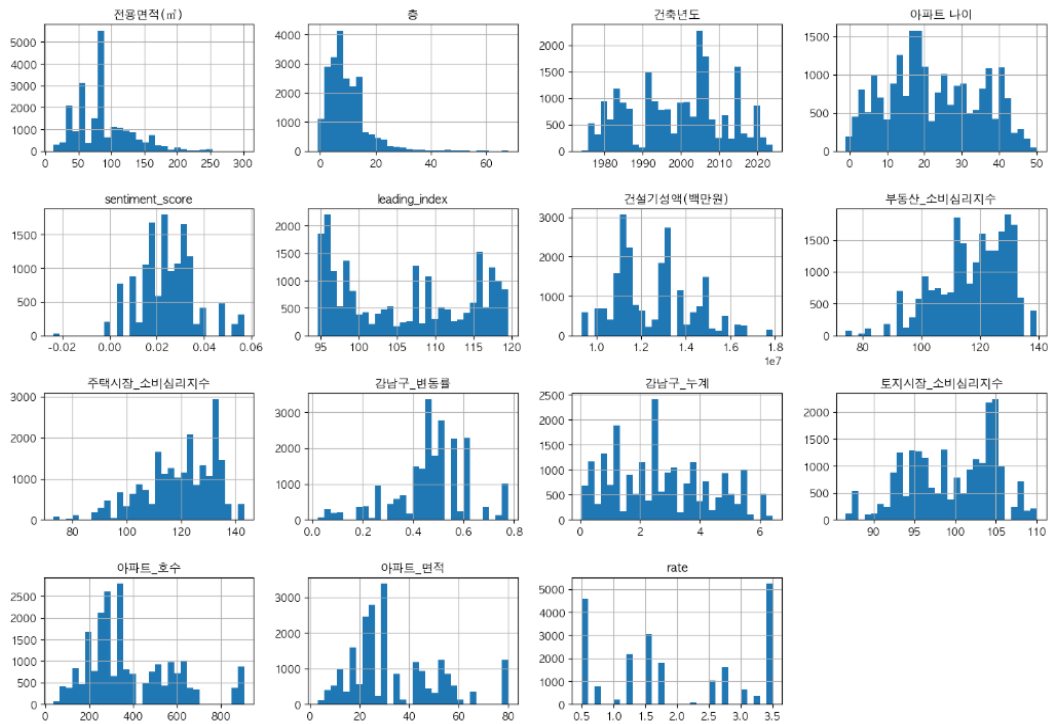
명 주소를 위도와 경도로 변환하였다. 이 좌표를 기준으로 GEE에서 위성 이미지 데이터를 추출하였다. 마지막으로 시나리오 분석의 핵심 동인이 되는 거시 경제지표는 두 가지 주요 출처에서 수집하였다. 부동산 관련 소비심리지수, 지가변동을 등은 한국부동산원 부동산 통계 정보 시스템(R-ONE)에서 제공하는 데이터를 활용하였으며, 특히 R-ONE의 ‘자주 찾는 통계표’를 기준으로 변수를 선정하였다. 이와 더불어, 기준 금리 데이터는 한국은행 경제통계시스템(ECOS)에서 수집하여 데이터셋을 완성하였다.

[표 4-2] 데이터 구성

데이터	세부사항	설명
아파트 매매	전용 면적	실제 거주자가 독립적으로 사용하는 면적
	층	해당 아파트 세대가 위치한 층수
	건축 연도	아파트 건물이 준공된 연도
	면적당 단가	아파트 매매가격을 전용 면적으로 나눈 값 (종속 변수)
	아파트 나이	계약 시점 기준, 건물이 지어진 후 경과한 시간
	계약 일자	아파트의 매매 계약이 체결된 시점
경제 지표	건설 기성액(백만원)	건설업체가 실제 시공한 공사 실적 금액
	부동산 소비 심리지수	부동산 시장에 대한 소비자의 종합적인 인식을 나타내는 지표
	주택시장 소비 심리지수	주택 시장에 대한 소비자의 인식을 나타내는 지표
	토지시장 소비 심리지수	토지 시장에 대한 소비자의 인식을 나타내는 지표
	아파트 매매 호수	해당 기간에 거래된 아파트의 총 호수 갯수
	아파트 매매 면적	해당 기간에 거래된 아파트의 총 면적
	강남구 지가 변동률	해당 기간 동안 강남구의 토지 가격의 변화율
	강남구 지가 누계	2005년 1월부터 현재까지 강남구의 지가 변동률의 누적 합계
	금리	한국은행 기준 금리
	경기 선행 지수	미래 경기 방향성을 예측하는 데 사용되는 지표
	위성 이미지	거래된 아파트를 기준으로 1.5Km 범위를 찍은 사진

#### 4.3.2 데이터 전처리

수집된 원본 데이터는 모델 학습의 성능과 안정성을 높이기 위해 다음과 같은 전처리 과정을 수행하였다. 아파트 매매 데이터에서 발생한 결측치는 수가 매우 적어 해당 행을 제거했으며, 거시 경제지표에서는 결측치가 발견되지 않았다. 정형 데이터의 수치형 변수들은 [그림 4-2]에서 볼 수 있듯이 다양한 분포 형태를 나타냈으며, 이러한 분포는 모델 학습을 불안정하게 만들 수 있으므로, 로그 변환을 통해 정규분포의 형태로 만드는 것을 시도하였다. 하지만 로그 변환을 적용해도 타겟변수인 면적당 단가를 제외한 다른 변수들은 분포에 큰 변화가 없어 타겟변수를 제외한 다른 변수들에는 로그 변환보다 좀 더 효과적인 Box-Cox 변환, 분위수 변환(Quantile Transform) 적용을 고려하였다. 또한 변수 간의 스케일 차이를 조정하기 위해 MinMaxScaler, StandardScaler, RobustScaler 세 가지 스케일링 기법의 적용도 함께 검토하였다.



[그림 4-2] 모든 수치형 변수 분포

먼저, 정형 변수들에 대해 분포 변환 기법 적용 여부에 따른 모델 성능 변화를 확인하는 실험을 진행하였다. 본 연구의 최종 모델 성능 비교 결과([표 5-2] 참조) TCN이 GRU, LSTM보다 우수한 성능을 보였으므로, 논문에는 TCN모델을 기준으로 한 결과만 표시하였다. [표 4-1]은 각 분포 변환 기법에 대한 MAE 결과이다. 비교 대상은 타겟 변수만 로그 변환을 한 상태, 분위 수 변환, Box-Cox 세 가지 경우이다. 실험 결과, 분포 변환을 적용하면 오히려 MAE가 증가하여 성능이 저하되는 경향을 보였다. 이는 분포 변환 과정에서 발생할 수 있는 정보 손실이나 왜곡이 모델 학습에 부정적인 영향을 미쳤을 가능성을 보인다. 따라서 정형 변수에는 타겟 변수만 로그 변환을 적용하기로 하였다.

[표 4-3] 정규화 기법 비교 표

정규화 기법 비교	1개월 후	3개월 후	6개월 후
Box-Cox	7.298	7.342	7.393
Quantile	7.374	7.404	7.452
Log (Target Only)	<b>7.207</b>	<b>7.322</b>	<b>7.382</b>

다음으로 입력 정형 변수에 적용할 최적의 스케일링 기법을 선정하기 위해 StandardScaler, RobustScaler, MinMaxScaler를 후보로 선정하였으며, 선정된 이유와 설명은 다음과 같다.

첫째, StandardScaler는 딥러닝 과제에서 가장 보편적으로 사용되는 기법으로, 각 피처의 평균을 0, 표준편차를 1로 변환한다. 둘째, RobustScaler는 중앙값과 IQR을 사용하여 스케일링하므로 이상치에 강건하다는 장점이 있다. [그림 4-3]에서 타겟 변수의 이상치가 확인되었으므로, 이러한 이상치 영향을 최소화하기 위해 후보로 추가하였다. 셋째, MinMaxScaler는 데이터의 최솟값을 0, 최댓값을 1로 변환하여, 신경망 모델의 입력 범위를 명확히 제한할 때 유리하다. [표 4-2]는 세 가지 스케일러를 적용하여 TCN 모델을 학습시킨 성능 비교 결과이다.

[표 4-4] 스케일링 기법 비교 표

스케일링 기법 비교	1개월 후	3개월 후	6개월 후
MinMax	<b>7.107</b>	<b>6.991</b>	<b>7.012</b>
Standard	7.182	7.254	7.201
Robust	7.165	7.231	7.182

[표 4-3]에서 볼 수 있듯이, MinMaxScaler를 사용했을 때 모든 예측 구간에서 가장 낮은 MAE를 기록하였다. 이는 TCN 모델은 입력 범위가 [0, 1]로 범위가 제한될 때 더 안정적으로 학습하는 특성을 보였기 때문으로 추정된다. 비록 MinMaxScaler가 이상치에 민감하다는 단점이 있지만, 본 연구의 데이터셋에는 오히려 이상치의 상대적 스케일 정보를 보존하는 것이 모델 학습에 긍정적인 영향을 미쳤을 수 있다. 이는 이상치가 포함된 시계열 데이터에 MinMaxScaler를 적용하여 우수한 딥러닝 모델 성능을 보고한 선행 연구[14]의 결과와도 일치하는 경향이다. 따라서 본 연구는 이러한 실험적 결과에 기반하여 MinMaxScaler를 최종 스케일링 기법으로 채택하였다.

위성 이미지는 사전 학습된 ResNet-50 모델의 표준 입력 크기에 맞게 224\*224픽셀로 크기를 조정하고, 픽셀값의 평균을 0, 분산을 1로 정규화하였다. 픽셀값을 정규화해도 시각적으로 다르게 보이는 점은 없음을 확인하였다. 이는 선행 연구의 이미지 데이터 정규화 과정에도 동일한 증상이 보였음을 확인하고 문제가 없다고 판단하였다[7]. 추가로, 딥러닝 모델의 과적합을 방지하고 일반화 성능을 높이기 위해 데이터 증강 기법을 적용하였다. 구체적으로는 RandomRotation 기법을 사용하여 각 위성 이미지를 0도에서 360도 사이 임의의 각도로 회전시켰으며, 회전 시 발생하는 빈 공간은 흰색으로 채웠다. 데이터 증강의 예시는 아래 [그림 4-4]와 같다.



[그림 4-3] 증강된 위성 이미지 예시

#### 4.3.4 정형 데이터 특징 추출

아파트의 개별 특성과 거시 경제지표로 구성된 정형 데이터는 MLP 모델을 통해 핵심 특징을 추출하였다. MLP는 64개의 뉴런을 가진 하나의 은닉층으로 구성되었으며, 활성화 함수로는 ReLU를 사용하였다. 이 과정을 통해 정형 데이터는 64차원의 벡터로 압축되었다.

#### 4.3.5 비정형 데이터 특징 추출

위성 이미지는 ResNet-50 모델을 특징 추출기로 활용하였다. ResNet-50의 최종 합성곱 레이어를 통과한 특징맵(feature map)은 2048차원의 고차원 벡터로 변환되었다. 이러한 고차원 벡터를 그대로 시계열 모델에 입력할 경우 너무 높은 차원으로 인해 계산 비용 및 메모리 요구가 기하급수적으로 늘어나 성능이 떨어질 수 있다[16]. 따라서 3개의 은닉층을 가지며 은닉층마다 128, 64, 32개의 뉴런을 가진 Dense Layer를 추가하여 이미지의 핵심 특징을 저차원의 벡터로 압축하여 차원의 저주 문제를 해결하였다.

#### 4.3.6 특징 데이터 융합

각 모델에서 추출된 정형 벡터와 비정형 벡터는 서로 다른 정보를 담고 있다. 이 두 벡터를 단순히 병합(merge)만 할 경우, 시계열 모델이 두 이질적인 정보 간의 복잡한 상호작용을 직접 학습해야 하는 부담이 생긴다. 이 부담을 해결하기 위해 병합된 벡터를 추가적인 하나의 은닉층에 256개의 뉴런을 가진 Dense Layer에 통과시켰다. 이 융합 계층은 두 특징 벡터 간의 비선형 관계를 학습하여, 데이터의 시너지가 반영된 하나의 통합된 표현을 생성하는 역할을 한다. 이를 통해 시계열 모델은 시간적 패턴 학습에만 더 집중할 수 있어 전체적인 예측 성능이 향상된다.


#### 4.3.7 모델 성능 평가

각 모델의 예측 성능을 평가하기 위해 MAE(mean absolute error, MAE)를 평가지표로 사용하였다. MAE는 실제값과 예측값 차이의 절댓값에 대한 평균으로 오류의 크기를 직관적으로 파악할 수 있으며, 이상치에 강한 모습 보여준다. 값이 낮을수록 모델의 성능이 우수함을 의미하며 수식은 다음과 같다.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

본 연구에서 MAE를 선택한 주된 이유는 다음과 같다.

[그림 4-4]의 박스 플롯에서 볼 수 있듯이, 타겟 변수인 ‘면적당 단가(만원)’의 원본 분포는 오른쪽으로 치우친 이상치를 포함하고 있다. 이러한 이상치 또한 강남구 부동산 시장의 고가 거래 특성을 반영하는 유의미한 데이터로 판단하여 제거하지 않고 모델 학습에 포함하였다.



[그림 4-4] 면적당 단가(만원)의 이상치

## 5. 실험

### 5.1 위성 이미지 효과성 검증

정형 데이터에 비정형 데이터인 위성 이미지 데이터가 예측 성능 향상에 기여하는지를 확인하기 위해 실험을 진행하였다. 초기 시도에서는 ResNet-50에서 추출한 2048차원의 고차원 벡터를 LSTM, GRU, TCN 모델에 직접 학습시켰으나 차원의 저주 현상으로 인해 MAE가 오히려 크게 증가하는 문제가 발생했다. 이 문제를 해결하기 위해, ResNet-50에서 추출한 고차원의 벡터를 128, 64, 32개의 뉴런을 가진 3개의 은닉층을 통과해 차원 수를 압축하였고, 정형 벡터와 비정형 벡터를 다시한번 256개의 뉴런을 가진 은닉층을 통과시켜 모델을 학습하였다. 아래 [표 5-1]은 비정형 데이터 특징을 추가하지 않은 베이스 모델과, 비정형 데이터를 추가 및 압축 방식을 적용한 모델의 성능을 비교한 결과이며 사용된 모델은 TCN이다.

[표 5-1] 비정형 데이터 활용 효과 결과

모델 구분	1개월 후	3개월 후	6개월 후
기준 모델	7.486	7.487	7.236
위성 이미지 결합 모델	7.137	7.212	7.156
감소율	4.66%	3.67%	1.11%

실험 결과 제안된 데이터 융합 방식이 모든 예측 구간에서 MAE를 감소시키며 예측 정확도를 향상시키는 것을 확인하였다. 이는 위성 이미지가 아파트 가격 예측에 유의미한 변수로 작용함을 의미한다.

### 5.2 경제지표 데이터 영향 분석

본 연구에서는 시나리오 분석의 기반이 되는 거시 경제지표의 영향을 검증하였다. 부동산 시장 분석에서 주로 활용되는 소비심리지수, 건설기성액 등을 모델 학습 데이터에 추가하였다. 이러한 경제지표를 추가했을 때 MAE가 소폭 증가하는 경향을 보였으나, 그 차이는 통계적으로 유의미하지 않다고 판단하였다. 또한 미래 변동성을 예측하는 시나리오 분석의 핵심 요인이라는 점을 고려하여 최종 모델에 경제지표를 포함하기로 하였다.

### 5.3 최종 모델 성능 비교

융합된 멀티모달 데이터셋의 복잡한 패턴을 학습하기 위한 최적의 모델을 선정하고자, 본 연구는 RNN 계열 모델(GRU, LSTM)과 CNN 기반 모델(TCN)의 성능을 직접 비교하였다. GRU와 LSTM은 시계열 과제에서 대표적으로 사용되는 모델이지만 2.1.5절에서 언급한 바와 같이 장기 의존성 및 연산 효율성 측면에서 한계가 지적됐다. 이에 본 연구는 그 대안으로 떠오른 TCN 모델을 주요 비교 대상으로 설정하였다. 세 모델의 비교 결과는 [표 5-2]와 같다.

[표 5-2] 최종 모델 성능 비교

예측 시점	GRU	LSTM	TCN
1개월 후	7.305	7.237	<b>7.219</b>
3개월 후	7.457	7.212	<b>7.210</b>
6개월 후	7.527	7.256	<b>7.242</b>



실험 결과 모든 예측 구간에서 TCN 모델이 가장 낮은 MAE를 기록하며 가장 우수한 성능을 보였다. 이는 TCN 모델이 가진 긴 시퀀스에 대한 기억 능력과 병렬 처리의 효율성이 복잡한 멀티모달 시계열 데이터 학습에 효과적임을 보여준것으로 추측된다. 이에 따라 최종 시나리오 분석에는 TCN 모델을 사용하였다.

#### 5.4 시나리오 설계

본 연구의 시나리오는 수동 설정 방식을 채택하였다. 이는 연구에 사용된 7년의 데이터 기간이 전체 경기의 순환을 모두 포함하기에는 충분하지 않을 수 있으며, 특정 기간의 특성에 편향된 통계적 시나리오가 생성될 위험을 배제하기 위함이다.

따라서 본 연구는 다음과 같은 상황을 기반으로 각 시나리오의 핵심 동인인 거시 경제지표의 경제지표 가중치를 설정하였다.

- 낙관적 시나리오: 글로벌 경기가 점진적으로 회복되고 기준 금리가 인하되며, 부동산 투자 심리가 개선되는 긍정적인 상황을 가정하였다.
- 중립적 시나리오: 현재의 거시 경제 상황이 큰 변동 없이 현재 추세를 그대로 유지하는 상황을 가정하였다.
- 보수적 시나리오: 경기 둔화 우려가 확산되고 추가적인 금리 인상이 단행되며, 부동산 시장의 투자 심리가 위축되는 부정적인 상황을 가정하였다.

시나리오별 적용된 구체적인 경제지표 가중치는 아래 [표 5-3]과 같으며, 수식은 다음과 같다.

$$E_{t+1} = E_t \times W$$

여기서  $E_t$ 는 시점  $t$ 시점의 거시 경제지표 값을 의미하며,  $W$ 는 [표 5-3]에서 정의한 시나리오별 경제지표 가중치를 나타낸다.

이 수식은 미래의 경제지표를 산출하기 위해, 직전 시점( $t$ )의 값에 설정된 가중치를 곱하여 다음 시점( $t+1$ )의 값을 도출하는 재귀적연산을 의미한다. 즉, 단순히 고정된 상수를 더하는 것이 아니라 매월 일정한 비율( $W$ )로 지표가 변동함을 가정한다. 이 과정을 예측 기간 동안 반복 수행함으로써 가중치의 효과가 누적되며, 결과적으로 시간이 경과할수록 시나리오 간의 경제적 상황 격차가 점진적으로 확대되도록 설계하였다.

[표 5-3] 시나리오별 경제지표 가중치

경제지표	낙관적	중립적	보수적
경기선행지수	1.002	1.0	0.998
건설기성액(백만원)	1.001	1.0	0.999
부동산 소비심리지수	1.003	1.0	0.997
주택시장 소비심리지수	1.003	1.0	0.997
토지시장 소비심리지수	1.002	1.0	0.998
강남구 변동률	1.002	1.0	0.998
강남구 누계	1.001	1.0	0.998
기준 금리	0.999	1.0	1.001

## 5.5 시나리오 예측

설계된 시나리오를 적용하기 위해 미래 12개월을 한 시점씩 순차적으로 예측하는 재귀적 방식을 사용하였다. 예측의 시작점으로는 전체 데이터셋의 가장 마지막 12개월 데이터를 초기 입력 시퀀스로 사용하였다.

재귀적 예측은 한 시점( $t$ )의 가격을 예측하면, 이 예측값과 위에서 정의된 시나리오 규칙을 사용하여 다음 시점( $t+1$ )을 예측하기 위한 가상의 입력 데이터를 생성하는 방식으로 이루어진다. 구체적으로, 가상의 미래 데이터는 다음과 같이 구성된다.

1. 아파트 고유 특성(면적, 층 등)과 위성 이미지 특징 벡터는 변하지 않는다고 가정하고 이전 시점의 값을 그대로 사용한다.
2. 가격 관련 특징은 방금 예측된 값으로 업데이트한다.
3. 거시 경제지표는 현재 시나리오(낙관적, 중립적, 보수적)에 정의된 변화율을 이전 시점의 지표에 곱하여 생성한다.

이 과정을 12개월 동안 반복하여 시나리오별 미래 가격 변동 추이를 도출하였다.

## 5.6 예측 결과


아래 [그림 5-1]은 시나리오별 미래 12개월 ‘면적당 단가(만원)’ 예측 결과를 시각화한 것이다. 예측 시작 시점인 2025년 8월부터 2025년 1월까지의 세 시나리오 모두 유사한 가파른 상승 추세를 보인다. 이는 초기 예측 구간에서는 과거 데이터의 영향력이 강하게 작용하며, 시나리오별 경제지표 변화의 누적 효과가 아직 미미하기 때문으로 해석된다. 그러나 2025년 1월 정점을 기록한 후, 2026년 3월까지의 세 시나리오 모두 일시적인 하락 또는 조정 국면에 진입하는 모습을 보인다. 이 구간부터 낙관적 시나리오와 보수적 시나리오 간의 격차가 점차 벌어지기 시작한다. 2026년 3월 이후에는 각 시나리오의 경로가 뚜렷하게 분기된다.

낙관적 시나리오는 조정 이후 가장 빠르게 반등하며 지속적인 상승세를 이어가, 예측 기간 말에는 가장 높은 가격 수준에 도달한다.

중립적 시나리오는 소폭 반등 후 비교적 완만한 상승세를 유지하며 안정적인 흐름을 보인다.

보수적 시나리오는 반등하지 못하고 횡보하거나 소폭 하락하는 추세를 보이며, 예측 기간 말에는 가장 낮은 가격 수준에 머무른다.

시간이 지남에 따라 시나리오 간의 가격 격차는 점차 확대되는 경향을 보인다. 이는 미래 거시 경제 환경의 변화 방향이 장기적으로 아파트 가격에 미치는 영향력이 상당함을 시사하며, 단일 예측값만으로는 파악하기 어려운 미래 시장의 변동성 범위를 시나리오 분석을 통해 효과적으로 제시할 수 있음을 보여준다.



[그림 5-1] 시나리오기반 아파트 가격 예측 결과

## 6. 결론

본 연구는 강남구 아파트 매매가격을 예측하기 위해 정형 데이터와 위성 이미지를 융합하는 멀티모달 접근법을 제안하고, TCN 모델을 활용하여 시계열 예측을 수행하였다. 실험 결과, 위성 이미지 특징을 추가했을 때 정형 데이터만 사용한 모델보다 예측 정확도가 향상됨을 확인하였으며, 비교 모델인 GRU, LSTM 대비 TCN 모델이 모든 예측 구간에서 가장 우수한 성능을 보였다. 나아가, 최종 선정된 TCN 모델에 수동으로 설계한 경제 시나리오를 적용하여 미래 12개월간의 가격 변동 범위를 낙관적, 중립적, 보수적 관점에서 성공적으로 전망하였다. 본 연구는 데이터 융합을 통해 시계열 예측 모델의 기술적 성능을 입증했을 뿐만 아니라, 미래 시장의 불확실성을 고려한 시나리오 분석 방법론을 부동산 가격 예측 분야에 적용하여 실용적인 가치를 제시했다는 점에서 의의가 있다.

향후 연구에서는 본 연구의 한계점을 보완하고 예측 모델을 더욱 고도화할 수 있을 것이다. 먼저, 연구의 공간적 범위를 강남구 외 다른 지역으로 확장하여 모델의 일반화 성능을 검증할 필요가 있다. 또한, 본 연구에서 사용한 데이터의 수집 기간이 상대적으로 짧았으므로, 장기간의 시계열 데이터를 확보하여 모델의 안정성과 예측력을 높이는 연구가 필요하다. 위성 이미지 외에 뉴스 기사 감성지수, 소셜 미디어 데이터, 스트리트 뷰 이미지 등 다양한 데이터 형태를 통합하고, 서로 다른 모달리티 데이터를 결합할 때 단순 병합 외에도 교차 주입, 특징 공간 변환 등 다양한 융합 방법을 적용하여 멀티모달 모델의 성능을 향상하는 연구를 시도할 수 있다. 마지막으로, 보다 정교한 모델이나 전문가의 의견을 반영하여 시나리오 설계를 고도화하고, 모델의 예측 근거를 설명하는 XAI 연구를 통해 모델의 신뢰도를 높이는 방향으로 연구를 확장할 수 있을 것으로 기대된다.

## 참고문헌

- [1] 통계청, “2024년 가계금융복지조사 결과”, <https://www.korea.kr/briefing/pressReleaseView.do?newsId=156664641>, 2024,12,09
- [2] 한국경제. “韓, 여전히 ‘아파트 불패신화’...‘가계 자산 80% 부동산 몰빵’”. <https://www.hankyung.com/article/2024041782271>, 2024.04.17
- [3] 한국은행. “국민대차대조표”. [https://www.chosun.com/economy/economy\\_general/2025/07/17/NK56CBTS5BH4THD2J2OCG5PQZI/](https://www.chosun.com/economy/economy_general/2025/07/17/NK56CBTS5BH4THD2J2OCG5PQZI/), 2025.07.17.
- [4] Hasan, M. H., et al. “House Price Prediction using Satellite Imagery”. arXiv, <https://arxiv.labs.arxiv.org/html/2105.06060>, 2024.10.02.
- [5] Hasan, M. H., et al. “A Multi-Modal Deep Learning Based Approach for House Price Prediction”. 2024.
- [6] Ali Nouriani, Lance Lemke, “Vision-based Housing Price Estimation using Interior, Exterior and Satellite Visual Attributes”. 2022.
- [7] 정현조, 김건우, 천세학. “커널밀도추정과 합성곱신경망을 이용한 아파트 가격 예측”, 한국진로교육학회 제37권 제6호
- [8] Bai, S., Kolter, J. Z., Koltun, V. “An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling”. 2018.
- [9] 조선비즈. “강남 3구 아파트 시가총액 ‘744조7264억원’...전체 서울 아파트의 43% 차지”. [https://biz.chosun.com/real\\_estate/real\\_estate\\_general/2025/07/03/DA555FEUPJHJLJCVM6W6LWVVHU/](https://biz.chosun.com/real_estate/real_estate_general/2025/07/03/DA555FEUPJHJLJCVM6W6LWVVHU/), 2025.09.22.
- [10] 배성완, 유정석. “기계 학습을 이용한 공동주택 가격 추정: 서울 강남구를 사례로”. 부동산학연구, 제24권 제1호, pp.69-85, 2023.
- [11] Bency, A. J., Rallapalli, S., Ganti, R. K., Srivatsa, M., Manjunath, B. S. “Beyond Spatial Auto-Regressive Models: Predicting Housing Prices with Satellite Imagery”. 2017 IEEE Winter Conference on Applications of Computer Vision (WACV), pp.305-313, 2017. doi:10.1109/WACV.2017.42.
- [12] Preparing for the future: scenario analysis for strategic planning,

<https://www.kaezn.com/insight/scenario-analysis>

- [13] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun, “Deep Residual Learning for Image Recognition”, Computer Vision and Pattern Recognition, 2015
- [14] Haowei Ni Shuchen Meng Xieming Geng Panfeng Li Zhuoying Li Xupeng Chen, “Time Series Modeling for Heart Rate Prediction: From ARIMA to Transformers“, IEEE, 2024
- [15] Shaojie Bai, J. Zico Kolter, Vladlen Koltun, “An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling”, arXiv, <https://arxiv.org/pdf/1803.01271>, 2018.4.19

## 부록